

התאוששות משיבושי טיסה

סוכן קולי יוצא בעברית לעדכון נוסעים ומתן החלטה מיידית

נכנס — מוקד סטטוס קולי 24/7

הנוסע מתקשר ומזדהה, ומקבל מענה מידי על סטטוס טיסה, כבודה ושינויי מושב — בלי המתנה בתור.

נבחר ✓

יוצא — עדכון יזום על שיבוש

כשטיסה מתעכבת או מתבטלת, הסוכן מתקשר יזום לכל נוסע, מעדכן ומציע טיסה חלופית או החזר כספי — בזמן אמת, ובמקבילות שאין למוקד אנושי.

היוזקייס הנבחר: התאוששות משיבוש טיסה

זרימת השיחה

זיהוי

1

אימות שמדובר בנוסע הנכון; טיפול במשיבון

עדכון

2

מסירת פרטי השיבוש: טיסה, שעה מקורית, משך העיכוב

הצגת אפשרויות

3

טיסה חלופית לעומת החזר כספי מלא

קבלת החלטה

4

סיווג לתשובה, בקשת נציג, או בקשת חזרה מאוחר יותר

סיכום וכתיבה

5

אישור בקול + כתיבת התוצאה חזרה למקור הנתונים

הבעיה

- ביטול או עיכוב טיסה מייצר עשרות עד מאות שיחות נכנסות תוך דקות
- גל השיחות מאריך זמני המתנה לכלל לקוחות המוקד, לא רק לנפגעי הטיסה
- עיכוב בהחלטת הנוסע (חלופית / החזר) מעכב שחרור מושבים ומכירה מחדש
- חוק שירותי תעופה (טיבי) מחייב מענה מהיר ומתועד לכל נוסע

ערך עסקי ו-ROI

חויית לקוח

עדכון אנושי ומהיר גם בשעות לא שגריות

הפחתת חשיפה רגולטורית

מענה מתועד לכל נוסע לפי דרישות חוק שירותי תעופה

החלמה תפעולית מהירה

החלטות נסגרות מוקדם — שחרור ומכירה מחדש של מושבים

בלימת גל שיחות

שיחה יזומה מונעת גל נכנס שמאריך המתנה לכלל הלקוחות

מודל ROI לדוגמה — הנחות גליות לאירוע שיבוש בודד

*ההנחות להלן הן דוגמה להמחשת מבנה החישוב, לא נתוני אל על בפועל

רכיב	אנושי בלבד	(AI) משולב	חיסכון
עלות לאירוע שיבוש (200 שיחות)	~1,870 ₪	~930 ₪	כ-50%
שיעור הכלה (AI סוגר לבד, שמרני)	—	65%	—
משך ועלות שיחה	דק' · ~80 ₪/שעה 7	דק' · ~0.45 ₪/דק' 3	—

לא רק חיסכון — יכולת חדשה

200 שיחות בו-זמנית ב-3 לפנות בוקר הן בלתי אפשריות עבור מוקד אנושי. הערך האמיתי הוא לא רק % חיסכון — אלא היכולת עצמה.

השוואת ארכיטקטורות ומודלים

Speech-to-Speech (Realtime)

Latency נמוך יותר (300-600ms), אך שליטה חלקית בטקסט, כיסוי עברית לא מובטח, ו-function calling פחות בשל.

נבחר ✓ Cascaded — STT → LLM → TTS


שליטה טקסטואלית מלאה בכל שלב, function calling בשל, ובחירת ספק מיטבי לכל רכיב. קריטי כשנדרש דטרמיניזם בנוסח ובמספרים.

המודלים שנבחרו — לאחר בדיקה בפועל

רכיב	נבחר	החלופה שנבדקה	הנימוק לבחירה
STT	Soniox (he)	Deepgram Nova-3	WER 1.8% בעברית, Keyterm Prompting, 410ms למספרי טיסה
TTS	Azure Hila	ElevenLabs	עברית טבעית ויציבה; ElevenLabs Flash לא תומך בעברית כלל
LLM	GPT-4.1 Mini	GPT-4.1	עברית תקינה בבדיקה + חצי מהעלות ו-90ms פחות latency

ארכיטקטורת המערכת

Airtable · FastAPI (Railway) · Vapi — זרימה דו-כיוונית



נקודות מפתח בזרימה

3 מסלולים

GET לבדיקת נתונים, POST להפעלת שיחה, POST לקבלת webhook

אבטחה

אימות חתימת (x-vapi-
webhook secret) + סודות רק ב-Environment Variables

חילוץ החלטה

ניתוח תמליל מקומי — לא תלוי בזמינות Structured Output של Vapi

עמידות

Retry עם exponential backoff, ותשובת 200 תמיד ל-Vapi כדי למנוע כפילויות

תוצאות ותובנות

שלוש שיחות יוצאות אמיתיות — הרשומות והוקלטו

נוסע	טיסה	החלטת הנוסע	סטטוס
יונתן כהן	LY315	החזר כספי מלא	הושלמה ✓
רוני לוי	LY315	טיסה חלופית	הושלמה ✓
דוד אברהם	LY315	בקשת נציג אנושי	הושלמה ✓

כל שיחה: זוהתה, עודכנה, קיבלה החלטה, וסוכמה חזרה למקור הנתונים אוטומטית — כולל טיפול נכון בבקשת נציג.

מגבלות שגילינו ומה הייתי משפר

לשיפור עתידי

טיפול בשלילה בזיהוי כוונה ("לא טיסה חלופית") ומעבר לזיהוי מבוסס-LLM עבור שיחות מורכבות יותר

התאמת ה"א" הידיעה בעברית

התאמת ביטויים דרשה נרמול של תחיליות ("הטיסה החלופית" מול "טיסה חלופית")

Structured Output א-סינכרוני

נתוני ניתוח של Vapi הגיעו באיחור/לא הגיעו כלל — הוחלף בניתוח תמליל מקומי הזמין מיידית

הגייה לא עקבית של ספרות

Azure TTS קרא שעות וספרות בצורה לא טבעית — נבנתה שכבת נרמול לעברית מדוברת ("רבע לחצות" ולא "23:45")